

Universidad Mariano Gálvez de Guatemala

Facultad de Ingeniería en Sistemas

CURSO: Inteligencia Artificial

CATEDRATICO: Ing. Carmelo Estuardo Mayen Monterroso

SEMESTRE: Noveno

CONTENIDO:

Informe Final

INTEGRANTES:

Brayan Josué Corado Robles

Daniel Antonio Ojeda Martinez

Julio Alberto Hernández Morales

Wayner Alberto López y López

Milton Adrian Martinez Ávila

CARNÉ:

1790-22-11094

1790-22-8309

1790-22-12000

1790-14-11226

1790-22-9129



Chiquimulilla, 30 de mayo de 2026

Índice

Contenido

Introducción	1
I. MARCO CONCEPTUAL	2
1.1 Antecedentes	2
1.2 Planteamiento del problema	3
1.3 Justificación	4
1.4 Objetivos	5
1.4.1 Objetivo general	5
1.4.2 Objetivos específicos	5
1.5 Alcances	5
1.5.2. Alcance Metodológico	5
1.5.3. Alcance Técnico	6
1.6 Límites	6
1.6.1. Límite Funcional	6
1.6.2. Límite Técnico	6
1.6.3. Límite Teórico	7
II. MARCO TEÓRICO	7
2.1. Inteligencia Artificial y Visión por Computadora en el Análisis Alimentario	7
2.2. Aprendizaje Profundo y Redes Neuronales Convolucionales (CNN)	9
2.3. Transfer Learning y la Arquitectura EfficientNet-B0	10
2.4. Fundamentos Nutricionales: El Sistema de Clasificación NOVA	12
2.5. Infraestructura Tecnológica para el Despliegue de Inteligencia Artificial	14
III. DESARROLLO DEL PROYECTO	15
3.1. Metodología de Trabajo y Arquitectura del Sistema	15
3.2. Justificación y Descripción de Clases Seleccionadas	16
3.3. Análisis de Datos (EDA) y Preprocesamiento	17
3.4. Entorno Tecnológico y Stack de Desarrollo	18
3.5. Configuración del Modelo de IA y Transfer Learning	21
3.6. Métricas de Evaluación y Análisis de Errores	22
3.6.1. Métricas Globales de Desempeño	22
3.6.2. Análisis de Errores Técnico	23
3.7. Consideraciones Éticas y Disclaimer Técnico	24
IV. Conclusiones	25

V. Recomendaciones.....	26
VI. Referencias Bibliográficas	27

Introducción

En la actualidad, la tecnología y la inteligencia artificial forman parte de muchas actividades de la vida diaria, incluyendo áreas relacionadas con la salud, la educación y la alimentación. Uno de los campos que más ha avanzado en los últimos años es la visión por computadora la cual permite que los sistemas informáticos puedan analizar imágenes y reconocer objetos, personas o alimentos de manera automática. Gracias a estos avances, hoy es posible desarrollar herramientas que ayuden a las personas a comprender mejor lo que consumen y a tomar decisiones más informadas sobre su alimentación.

En Guatemala, la alimentación representa un tema importante debido al aumento en el consumo de productos procesados y bebidas azucaradas, así como a la dificultad que muchas personas tienen para identificar el nivel de procesamiento de los alimentos que consumen diariamente. El país cuenta con una gran variedad de frutas locales y productos de consumo cotidiano que forman parte de la alimentación habitual de la población. Sin embargo, no siempre existe suficiente información práctica y accesible que permita diferenciar con rapidez entre alimentos frescos, procesados y ultraprocesados en el entorno cotidiano.

El presente proyecto surge como una propuesta educativa que busca combinar inteligencia artificial y nutrición mediante el desarrollo de una aplicación web capaz de analizar fotografías de alimentos y clasificarlas en categorías nutricionales como Fresco/Saludable, Procesado, Ultraprocesado o Bebida azucarada. La aplicación mostrará el nombre del alimento detectado, su categoría, un consejo educativo y el nivel de confianza de la predicción realizada por el modelo, con el objetivo de promover una mayor conciencia sobre hábitos de alimentación saludable dentro del contexto guatemalteco.

Asimismo, el presente documento describe el proceso de investigación y desarrollo del sistema, incluyendo los conceptos relacionados con inteligencia artificial, visión por computadora, redes neuronales convolucionales y clasificación nutricional basada en el sistema NOVA y las Guías Alimentarias para Guatemala.

I. MARCO CONCEPTUAL

1.1 Antecedentes

Según **Crystal (2024)**, en la actualidad las aplicaciones móviles basadas en visión por computadora han comenzado a tener un papel importante en la clasificación de alimentos, la estimación de porciones y la orientación nutricional. Los autores señalan que este tipo de soluciones permite analizar imágenes de comida de manera más práctica y rápida que los métodos tradicionales, lo cual resulta útil para apoyar procesos de educación alimentaria y seguimiento de hábitos de consumo. Este avance demuestra que el uso de inteligencia artificial en el área de la nutrición ya no se limita a la investigación, sino que también puede trasladarse a herramientas accesibles para el usuario común.

De igual manera, **Liu, Y., Zhang, H., Chen, X., & Wang, J (2025)** explican que el reconocimiento de alimentos mediante aprendizaje profundo ha evolucionado con rapidez gracias al uso de redes neuronales convolucionales, técnicas de transferencia de aprendizaje y modelos cada vez más eficientes para trabajar con imágenes. En su revisión sobre reconocimiento de alimentos, los autores destacan que estos sistemas pueden aprender a identificar patrones visuales como formas, texturas y colores, lo que facilita la clasificación automática de platos y productos alimenticios. Sin embargo, también indican que todavía existen retos importantes, como la variación de iluminación, la presentación de los platos y la diversidad cultural de las comidas, aspectos que hacen necesario entrenar modelos con datos más cercanos al contexto real donde se utilizarán.

También por otra parte, **Monteiro, C. A., Cannon, G., Moubarac, (2018, 2019)** plantean que la clasificación NOVA permite comprender los alimentos según el nivel y el propósito de su procesamiento industrial, dividiéndolos en cuatro grupos: alimentos frescos o mínimamente procesados, ingredientes culinarios, alimentos procesados y ultraprocesados. Los autores sostienen que esta forma de clasificación es útil porque no solo toma en cuenta qué alimento es, sino también cómo fue transformado antes de llegar al consumidor. En el caso de un proyecto educativo, esta base teórica resulta muy valiosa, ya que permite mostrar de forma sencilla si un alimento pertenece a una opción más natural o a un producto altamente industrializado.

En este contexto, el presente proyecto se enmarca en la necesidad de desarrollar una aplicación web con inteligencia artificial que permita clasificar fotografías de alimentos en categorías nutricionales de forma educativa. Su finalidad es ayudar a reconocer alimentos como bebidas azucaradas y productos empacados, para que el usuario pueda identificar con mayor facilidad qué tan procesado está lo que consume y tomar decisiones más informadas sobre su alimentación.

1.2 Planteamiento del problema

En la actualidad muchas personas en Guatemala consumen alimentos sin conocer con claridad si se trata de productos frescos, procesados, ultraprocesados o bebidas azucaradas. En la vida diaria esto puede ser difícil de identificar porque algunos alimentos parecen saludables a simple vista, pero en realidad contienen altos niveles de azúcar, grasa, sodio o ingredientes industriales. Esto puede influir en decisiones de alimentación poco adecuadas y, con el tiempo, afectar la salud de la población.

Ante esta situación surge la necesidad de desarrollar una aplicación web con inteligencia artificial que permita analizar fotografías de alimentos y clasificarlos de manera educativa en categorías nutricionales sencillas. De esta forma, el usuario podrá recibir una orientación rápida y clara sobre el tipo

de alimento que observa, fortaleciendo su aprendizaje y apoyando la toma de decisiones más informadas sobre su alimentación diaria.

1.3 Justificación

En la actualidad la alimentación ocupa un lugar muy importante en la vida de las personas, ya que de ella depende en gran medida la salud y el bienestar general. Sin embargo, muchas veces los consumidores no tienen claro si un alimento que observan o consumen es fresco, procesado, ultraprocesado o una bebida azucarada

Ante esta situación, el uso de inteligencia artificial aplicada al reconocimiento de imágenes representa una alternativa útil para apoyar la educación alimentaria. Un sistema basado en visión por computadora puede analizar fotografías de alimentos y ofrecer una clasificación rápida, sencilla y fácil de entender para cualquier persona. Esto permite convertir una tecnología avanzada en una herramienta práctica, que no solo identifica alimentos, sino que también ayuda a comprender mejor qué tan conveniente puede ser su consumo dentro de una alimentación equilibrada.

Además, el desarrollo de una aplicación web facilita que esta información llegue a más personas, ya que puede utilizarse desde un teléfono celular o una computadora sin necesidad de conocimientos técnicos especializados. A diferencia de un folleto o una explicación larga, una aplicación permite mostrar el resultado de manera inmediata, visual y clara, lo cual favorece el aprendizaje. Esta característica es especialmente importante en contextos donde se necesita información rápida, accesible y adaptada a la realidad local.

Por lo tanto este proyecto se justifica porque une tecnología, educación y contexto guatemalteco en una sola herramienta útil para la población. Su desarrollo contribuye a que las personas puedan tomar decisiones más informadas sobre lo que comen, comprendiendo de forma sencilla la diferencia entre un alimento fresco, uno procesado y uno ultraprocesado. Además, representa una propuesta innovadora que puede servir como base para futuras mejoras en educación nutricional apoyada por inteligencia artificial.

1.4 Objetivos

1.4.1 Objetivo general

Desarrollar una aplicación web con lenguaje Python que clasifique fotografías de alimentos o bebidas en una de las categorías establecidas: Fresco/Saludable, Procesado, Ultraprocesado o Bebida azucarada, mostrando al usuario el nombre del alimento detectado, su categoría, un consejo educativo y el nivel de confianza.

1.4.2 Objetivos específicos

- Crear un modelo de aprendizaje automático basado en EfficientNet-B0 para reconocer en tiempo real imágenes de alimentos.
- Clasificar alimentos en categorías fáciles de interpretar: fresco/saludable, procesado, ultraprocesado y bebida azucarada.
- Mostrar resultados de forma clara, con mensajes educativos y recomendaciones sencillas.
- Integrar una interfaz web fácil de usar desde computadora o teléfono.

1.5 Alcances

1.5.1. Alcance Funcional

El sistema abarcará las funciones relacionadas con la carga o captura en tiempo real de imágenes de alimentos, el análisis visual mediante el modelo de inteligencia artificial, la clasificación en categorías nutricionales y la presentación de resultados con mensajes educativos.

1.5.2. Alcance Metodológico

Para desarrollar la investigación se tomará como base una metodología de aprendizaje profundo aplicada al reconocimiento de imágenes, utilizando la arquitectura EfficientNet-B0 mediante Transfer Learning. Este enfoque permitirá organizar el proceso de entrenamiento, validación y evaluación del

modelo de forma ordenada, considerando además la clasificación NOVA y las Guías Alimentarias para Guatemala como apoyo conceptual para la orientación educativa.

1.5.3. Alcance Técnico

La aplicación se desarrollará utilizando Python y Streamlit, con apoyo de herramientas de procesamiento de imágenes. El sistema permitirá procesar fotografías digitales, redimensionarlas, normalizarlas y generar una predicción en tiempo corto. La solución estará diseñada para funcionar como una herramienta web accesible desde computadora o dispositivo móvil.

1.6 Límites

1.6.1. Límite Funcional

La aplicación se limitará a clasificar visualmente alimentos a partir de fotografías y a brindar orientación educativa básica. No realizará diagnósticos médicos, no sustituirá la asesoría de un nutricionista y no generará dietas personalizadas. Tampoco determinará con exactitud cantidades nutricionales, calorías o composición química de los alimentos.

1.6.2. Límite Técnico

El sistema dependerá de la calidad de las imágenes ingresadas, por lo que factores como mala iluminación, ángulos poco claros, fondo complicado o baja resolución pueden afectar la precisión de la clasificación. Además, el modelo estará limitado por la cantidad y variedad de imágenes utilizadas en su entrenamiento, especialmente en relación con platos tradicionales y presentaciones distintas de un mismo alimento.

1.6.3. Límite Teórico

La investigación se fundamentará en conceptos de inteligencia artificial, visión por computadora, redes neuronales convolucionales y clasificación nutricional basada en el sistema NOVA y las Guías Alimentarias para Guatemala. Sin embargo, el proyecto tendrá un enfoque únicamente educativo, por lo que no incluirá diagnósticos médicos, análisis clínicos ni evaluaciones nutricionales especializadas.

II. MARCO TEÓRICO

2.1. Inteligencia Artificial y Visión por Computadora en el Análisis Alimentario

La Inteligencia Artificial (IA) se define formalmente como el campo de la ciencia de la computación dedicado al diseño y desarrollo de sistemas informáticos capaces de ejecutar tareas que, históricamente, requerían de procesos cognitivos humanos, tales como el aprendizaje adaptativo, el razonamiento lógico y la percepción sensorial. Dentro de esta vasta disciplina, la Visión por Computadora (Computer Vision) constituye una de las ramas de mayor crecimiento y relevancia en la actualidad. Su objetivo primordial es dotar a los ordenadores de la capacidad de adquirir, procesar, analizar e interpretar de forma automatizada imágenes digitales o secuencias de video del mundo real, transformando datos bidimensionales de píxeles en información semántica y conocimiento estructurado.

En el ámbito del reconocimiento de alimentos, la visión por computadora se enfrenta a desafíos intrínsecos de alta complejidad, tales como la variabilidad en las condiciones de iluminación ambiental, los cambios en la disposición y estética de los platos, y la profunda diversidad cultural en la presentación de preparaciones culinarias. Para mitigar estos factores de ruido visual y optimizar la eficiencia del procesamiento, las arquitecturas modernas dividen el análisis en módulos secuenciales. Una técnica fundamental en esta etapa es el aislamiento de una Región de Interés (Region of Interest o ROI), que consiste en delimitar de manera matemática el área exacta de la imagen que contiene el

objeto principal de estudio (el alimento), descartando elementos periféricos o fondos complejos que puedan inducir a errores en las fases posteriores de clasificación.

Para llevar a cabo la detección y segmentación de la ROI en tiempo real, el sistema se fundamenta en herramientas avanzadas de visión artificial digital a través de la biblioteca especializada OpenCV. Este proceso metodológico tradicional involucra tres operaciones clave:

- **Procesamiento en el espacio de color HSV:** A diferencia del modelo convencional RGB (Rojo, Verde, Azul), el cual es altamente sensible a las fluctuaciones de luz debido a que la intensidad está acoplada a los canales cromáticos, el espacio de color HSV segmenta la información en Matiz (Hue), Saturación (Saturation) y Valor o Brillo (Value). Al aislar la componente cromática (matiz) de los cambios lumínicos (valor), el sistema adquiere una robustez matemática superior frente a sombras y destellos ambientales.
- **Segmentación por color y detección de contornos:** Mediante la aplicación de umbrales morfológicos (thresholding) en el espectro HSV, se aíslan los rangos cromáticos característicos del alimento. Posteriormente, se ejecutan algoritmos topológicos para identificar los contornos, definidos como las curvas continuas que unen todos los puntos que delimitan las fronteras de una forma geométrica continua.
- **Delimitación mediante Bounding Boxes:** Una vez evaluados y jerarquizados los contornos por su relevancia espacial, el sistema calcula analíticamente un rectángulo contenedor (bounding box) que encierra los píxeles de la ROI. Esto asegura que el subsiguiente modelo de aprendizaje profundo reciba una matriz de datos limpia y enfocada exclusivamente en el producto a clasificar, reduciendo el costo computacional de la inferencia.

2.2. Aprendizaje Profundo y Redes Neuronales Convolucionales (CNN)

El **Aprendizaje Profundo** (Deep Learning) representa una subcategoría avanzada del aprendizaje automático (Machine Learning) basada en el empleo de redes neuronales artificiales profundas compuestas por múltiples capas de procesamiento abstracto. La ventaja disruptiva del Deep Learning radica en su capacidad para realizar una extracción automática de características jerárquicas a partir de datos brutos, eliminando la necesidad de diseñar descriptores visuales de forma manual.

Para el procesamiento de datos con estructura matricial o espacial, como las imágenes, las Redes Neuronales Convolucionales (CNN) constituyen el estándar de la industria debido a su arquitectura inspirada en la organización de la corteza visual biológica. Una CNN procesa la información de forma progresiva a través de tres tipologías de capas fundamentales:

- **Capas Convolucionales (Convolutional Layers):** Son el núcleo de la red. Aplican operaciones de convolución matemática mediante el deslizamiento de filtros bidimensionales (kernels) sobre la imagen de entrada. En las primeras capas convolucionales, la red detecta características primitivas de bajo nivel como bordes rectos, esquinas y gradientes de color; a medida que se avanza hacia capas más profundas, los mapas de características (feature maps) se combinan para reconocer estructuras de alto nivel, tales como texturas complejas, siluetas e identidades geométricas específicas de los alimentos.
- **Capas de Agrupación (Pooling Layers):** Intercaladas entre las capas convolucionales, estas funciones (comúnmente Max-Pooling) realizan un submuestreo espacial que reduce las dimensiones de los mapas de características. Esto disminuye la cantidad de parámetros libres de

la red y el tiempo de cómputo, además de otorgar invariancia ante pequeñas traslaciones, rotaciones o deformaciones del objeto dentro del encuadre.

- **Capas Completamente Conectadas (Fully Connected Layers):** Ubicadas en la fase terminal de la arquitectura, estas capas conectan cada neurona de la capa anterior con las neuronas de salida. Toman el vector de características abstractas previamente aplanado y aplican funciones de activación matemática (como Softmax) para computar una distribución de probabilidad, asignando formalmente el objeto analizado a una de las clases definidas en el sistema.

2.3. Transfer Learning y la Arquitectura EfficientNet-B0

El entrenamiento de una red neuronal convolucional robusta desde cero requiere de repositorios masivos de datos (millones de imágenes etiquetadas) y una infraestructura de hardware altamente sofisticada que exige extensas jornadas de cómputo. Con el propósito de sortear estas restricciones en entornos de desarrollo específicos, la ingeniería de software emplea el método de Transferencia de Aprendizaje (Transfer Learning).

Esta técnica metodológica se basa en la reutilización de un modelo que ha sido previamente entrenado en un conjunto de datos genérico y masivo de escala global, como ImageNet (el cual almacena más de 14 millones de imágenes distribuidas en miles de categorías). Al aplicar Transfer Learning, el modelo aprovecha los pesos matemáticos preentrenados que ya son capaces de extraer características visuales esenciales (formas, texturas, iluminación). Posteriormente, se realiza una adaptación y sintonización fina (fine-tuning) de la última capa clasificadora, reconfigurándola para mapear y discernir con alta precisión un conjunto de clases propio y contextualizado (en este proyecto, un dataset personalizado de 21 clases alimenticias).

Para este sistema, se seleccionó la arquitectura EfficientNet-B0 como el modelo base para la extracción de características y clasificación. Desarrollada por Tan y Le (Google Research), la familia de redes EfficientNet introdujo un paradigma innovador denominado Escalamiento Compuesto (Compound Scaling). Tradicionalmente, para incrementar la precisión de una CNN, los desarrolladores escalaban una sola dimensión de la red de manera arbitraria: agregando más capas (profundidad), incrementando el número de canales por capa (ancho) o aumentando la resolución de la imagen de entrada. El Escalamiento Compuesto demuestra matemáticamente que existe una relación simétrica entre estas tres variables, por lo que utiliza un coeficiente de escala fijo para expandir de forma uniforme y equilibrada el ancho, la profundidad y la resolución del modelo.

La variante EfficientNet-B0 destaca en la literatura científica debido a sus propiedades operacionales óptimas:

- **Eficiencia Computacional:** Consigue niveles de precisión comparables e incluso superiores a redes significativamente más densas (como ResNet-50) pero utilizando una cantidad drásticamente menor de parámetros entrenables y operaciones de punto flotante (FLOPs).
- **Compatibilidad con Tiempo Real en CPU:** Gracias a su optimización estructural y su baja demanda de memoria RAM, permite ejecutar inferencias predictivas a velocidades sumamente altas directamente sobre Unidades Centrales de Procesamiento (CPU), eliminando la dependencia estricta de costosas GPUs en la etapa de despliegue y haciéndola ideal para aplicaciones web e interactivas.

Para que las imágenes capturadas en tiempo real puedan ser procesadas de manera correcta por los tensores de EfficientNet-B0, se debe ejecutar una etapa matemática rigurosa de preprocesamiento:

1. **Redimensionamiento estructural (Resize):** Ajuste espacial obligatorio de las dimensiones de la imagen a una matriz fija y cuadrada de 224x224 píxeles.

2. **Normalización estadística estándar:** Transformación de los valores de intensidad de los canales de color (RGB) empleando la media ($\mu = [0.485, 0.456, 0.406]$) y la desviación estándar ($\sigma = [0.229, 0.224, 0.225]$) precalculadas de la base de datos ImageNet, asegurando la estabilidad numérica y la coherencia en las predicciones del modelo.

2.4. Fundamentos Nutricionales: El Sistema de Clasificación NOVA

Desde la perspectiva de las ciencias de la salud y la nutrición pública, el análisis convencional centrado estrictamente en el conteo calórico o en la cuantificación aislada de macronutrientes (carbohidratos, grasas, proteínas) resulta insuficiente para evaluar el impacto real que la industrialización y los aditivos químicos modernos ejercen sobre el organismo humano. Con el fin de aportar un marco teórico riguroso y de alto valor pedagógico, este proyecto adopta el Sistema de Clasificación NOVA, una metodología validada globalmente por organismos internacionales como la Organización Panamericana de la Salud (OPS) y la Organización Mundial de la Salud (OMS), desarrollada originalmente por el equipo de investigación liderado por el Dr. Carlos Monteiro en la Universidad de São Paulo.

El sistema NOVA clasifica los alimentos no por sus propiedades químicas intrínsecas, sino en función del grado, extensión y propósito del procesamiento industrial al que son sometidos antes de llegar al consumidor final. El modelo teórico de NOVA establece formalmente cuatro grupos diferenciados:

1. **Alimentos sin procesar o mínimamente procesados:** Comprende las partes de plantas o animales obtenidas directamente de la naturaleza (frutas, verduras, frutos secos, carnes, huevos) que no han sufrido modificaciones industriales, o bien que han sido sometidas a procesos mínimos indispensables (limpieza, descascarillado, pasteurización, congelación o envasado al vacío) orientados exclusivamente a prolongar su vida útil natural, sin la adición de sal, azúcar, aceites o aditivos cosméticos.

2. **Ingredientes culinarios procesados:** Sustancias obtenidas de la naturaleza o de componentes del Grupo 1 mediante procesos físicos y químicos como el prensado, la molienda, la refinación o la extracción (aceites vegetales, mantequilla, manteca, sal y azúcar de mesa). Su función exclusiva es facilitar la cocción y el sazón de las preparaciones culinarias caseras.
3. **Alimentos procesados:** Productos manufacturados de estructura sencilla que se elaboran adicionando ingredientes del Grupo 2 (sal, azúcar o aceites) a alimentos del Grupo 1. Su propósito es aumentar la estabilidad temporal de los alimentos o alterar agradablemente sus cualidades organolépticas (legumbres en conserva, quesos artesanales, panes tradicionales, frutas en almíbar).
4. **Alimentos ultraprocesados:** Formulaciones industriales de alta complejidad tecnológica elaboradas en su totalidad o en su mayor parte a partir de sustancias derivadas de componentes alimentarios (almidones, azúcares modificados, aceites hidrogenados, proteínas aisladas) y aditivos químicos de síntesis industrial (colorantes, potenciadores de sabor, emulsionantes, edulcorantes artificiales). Estos productos carecen habitualmente de alimentos enteros reconocibles y están diseñados para ser altamente palatables, duraderos y de consumo inmediato, poseyendo una elevada densidad calórica y un perfil nutricional deficiente.

Para garantizar una visualización intuitiva, de rápida asimilación educativa y adaptada a una interfaz de usuario interactiva, este proyecto consolida los lineamientos de NOVA en cuatro categorías diana:

Fresco/Saludable, Procesado, Ultraprocesado y Bebida azucarada. La decisión metodológica de independizar las "Bebidas azucaradas" como una categoría propia responde a criterios epidemiológicos críticos, dada su alta prevalencia de consumo masivo en la población y su impacto patológico directo en el desarrollo de enfermedades crónicas no transmisibles como la diabetes mellitus tipo 2, la obesidad y el síndrome metabólico.

2.5. Infraestructura Tecnológica para el Despliegue de Inteligencia Artificial

La materialización de este marco teórico en una solución de software escalable, interactiva y accesible requiere de un entorno tecnológico unificado bajo el lenguaje de programación de alto nivel Python 3.10, seleccionado por su madurez y dominancia en el ecosistema de la inteligencia artificial y la computación científica. La infraestructura de librerías y frameworks que sustentan el funcionamiento del sistema se fundamenta en:

- **PyTorch y Torchvision:** PyTorch actúa como el framework de Deep Learning de código abierto principal, proveyendo las estructuras de datos matriciales complejas (tensores), los grafos de computación dinámica y las rutinas de cálculo optimizadas esenciales para cargar los pesos del modelo neuronal y ejecutar la inferencia predictiva de probabilidades matemáticas. Complementariamente, Torchvision suministra las primitivas de visión computacional, los pesos base de la arquitectura EfficientNet-B0 y las funciones de transformación estructural necesarias para aplicar el preprocesamiento de ImageNet de manera eficiente.
- **Streamlit y streamlit-webrtc:** Streamlit provee un entorno ágil de desarrollo para convertir scripts funcionales de Python en interfaces web interactivas y dinámicas, facilitando al usuario final la visualización inmediata de los resultados, los porcentajes de confianza y las recomendaciones educativas. Por su parte, la extensión streamlit-webrtc resulta indispensable para la operación en tiempo real, ya que integra el protocolo WebRTC (Web Real-Time Communication) directamente en el navegador del usuario. Esto habilita la captura, codificación y transmisión fluida de transmisiones de video bidireccionales de baja latencia desde la cámara del dispositivo móvil o computadora portátil del cliente hacia el servidor web, permitiendo un flujo continuo de fotogramas para su análisis analítico inmediato sin necesidad de instalar extensiones de software de terceros.

- **NumPy y Pillow (PIL):** NumPy proporciona la base de computación numérica de alta velocidad mediante el soporte para arreglos multidimensionales densos, formato matemático exacto en el cual las imágenes son traducidas y manipuladas como matrices numéricas por los algoritmos de visión artificial. Pillow opera como la librería nativa para la gestión de archivos de imagen, permitiendo la lectura, conversión de perfiles de color y reestructuración de bits de manera eficiente.

Esta robusta cohesión conceptual y tecnológica respalda los resultados experimentales documentados en la investigación, haciendo posible alcanzar métricas de desempeño excepcionales que registran un Accuracy global cercano al 99.90% y un nivel de confianza promedio superior al 99.73% sobre el conjunto de validación, asegurando la entrega de una plataforma de orientación nutricional altamente precisa, veloz y de gran impacto socioeducativo dentro del contexto guatemalteco.

III. DESARROLLO DEL PROYECTO

3.1. Metodología de Trabajo y Arquitectura del Sistema

El desarrollo de este sistema automatizado se rige bajo una metodología de ingeniería de software ágil e iterativa, orientada al despliegue continuo de modelos de aprendizaje profundo en entornos web. La arquitectura lógica del sistema está diseñada de forma modular para procesar transmisiones de video en tiempo real de manera eficiente, segmentando el ciclo de vida del dato en tres fases consecutivas:

1. Fase de Visión por Computadora (Captura y Aislamiento de la ROI): Utilizando el flujo de fotogramas generado por la cámara del usuario, el sistema implementa la biblioteca OpenCV para delimitar una Región de Interés (Region of Interest o ROI). En lugar de sobrecargar la red neuronal

analizando elementos aleatorios del fondo, este módulo transforma la imagen al espacio cromático HSV, aplica umbrales de binarización y extrae los contornos topológicos del objeto más prominente (el alimento), encuadrándolo dinámicamente mediante una caja contenedora (bounding box).

2. Fase de Inferencia por Aprendizaje Profundo (Core de IA): La submatriz limpia de la ROI es capturada por el backend, donde se somete a un pipeline de transformaciones matemáticas estrictas (redimensionamiento matricial y normalización estadística). Posteriormente, el tensor resultante se propaga a través de la red convolucional EfficientNet-B0, la cual procesa las características abstractas y calcula de forma probabilística la pertenencia del objeto a una de las categorías entrenadas utilizando la función de activación Softmax.

3. Fase de Interacción y Frontend (Presentación de Resultados): Construida íntegramente sobre el framework Streamlit, la interfaz web intercepta la predicción del modelo y realiza una consulta desacoplada a un diccionario estructurado en formato JSON. A partir de este mapeo, despliega de forma interactiva en la pantalla del usuario la etiqueta del alimento, el porcentaje de confianza analítico, su clasificación correspondiente dentro del paradigma nutricional NOVA y un consejo educativo personalizado con enfoque cultural local.

3.2. Justificación y Descripción de Clases Seleccionadas

Para la consolidación de este proyecto, se estructuró y curó un dataset personalizado compuesto por 21 clases alimenticias estratégicamente seleccionadas. La inclusión de cada clase responde a criterios técnicos de variabilidad visual y a una profunda justificación epidemiológica y sociocultural dentro del contexto de la salud pública en Guatemala:

- **Representación del Ecosistema Agrícola y Nutricional Local:** Se incluyeron frutas endémicas y de consumo diario como la manzana y el mango. Estas clases representan el Grupo 1 del sistema NOVA (Alimentos mínimamente procesados) y sirven como base para educar al usuario sobre los beneficios de priorizar alimentos naturales y ricos en micronutrientes según las Guías Alimentarias para Guatemala (GABA).
- **Evaluación del Impacto de la Comida Rápida y Procesada:** Clases como pizza y tacos fueron integradas debido a su alta disponibilidad en entornos urbanos. Visualmente, estas clases imponen un reto de alta complejidad debido a su naturaleza geométrica heterogénea (mezcla de texturas, ingredientes esparcidos y formas variables). Nutricionalmente, su identificación permite al sistema alertar sobre el consumo de grasas saturadas y carbohidratos refinados de manera moderada u ocasional.
- **Aislamiento Epidemiológico de Bebidas de Alto Riesgo:** Se determinó separar de forma explícita las clases agua pura y coca cola (u otras bebidas carbonatadas). Esta decisión metodológica se justifica por la alarmante prevalencia de enfermedades metabólicas y diabetes mellitus tipo 2 en la población guatemalteca, vinculada directamente al consumo masivo de bebidas ultraprocesadas. Aislar estas clases permite al frontend emitir alertas visuales críticas y sugerir de forma inmediata la sustitución de azúcares libres por hidratación natural.

3.3. Análisis de Datos (EDA) y Preprocesamiento

Antes de someter el dataset al proceso de optimización del clasificador, se ejecutó un Análisis Exploratorio de Datos (EDA) para evaluar el balance de cargas entre las 21 categorías y verificar la variabilidad de iluminación, ángulos y resoluciones. Para mitigar los sesgos de captura y unificar el flujo

de entrada que exige la red neuronal, se diseñó un pipeline de preprocesamiento matemático estricto compuesto por las siguientes operaciones secuenciales:

Redimensionamiento Estructural (Resize): Cada imagen cruda o ROI aislada por OpenCV es interpolada espacialmente para adaptarla a una matriz cuadrada fija de 224x224 píxeles, cumpliendo con los requisitos de dimensión de los tensores de la primera capa convolucional de la red.

Conversión a Tensores de PyTorch: La matriz de píxeles en formato de color RGB es mapeada desde su rango analógico entero $[0, 255]$ hacia un espacio numérico continuo de punto flotante en el rango $[0.0, 1.0]$.

Normalización Estadística ImageNet: Con el fin de estabilizar el gradiente durante el entrenamiento y evitar que los pesos matemáticos diverjan, los canales cromáticos del tensor se normalizan restando la media y dividiendo entre la desviación estándar precalculadas del dataset ImageNet: Media = $[0.485, 0.456, 0.406]$, Desviación Estándar = $[0.229, 0.224, 0.225]$.

3.4. Entorno Tecnológico y Stack de Desarrollo

La implementación del sistema web interactivo se consolidó bajo el lenguaje de programación Python 3.10, seleccionado específicamente por su robustez, madurez de sintaxis y su posición dominante como estándar de la industria en los ecosistemas de inteligencia artificial y computación científica. A continuación, se detalla la matriz de dependencias tecnológicas y el rol funcional de cada librería utilizada:

Librería / Componente	Versión / Ecosistema	Rol Crítico y Aplicación en el Sistema
Python 3.10	Núcleo de Software	Lenguaje principal del proyecto. Soporta la lógica de negocio y unifica las API de procesamiento gráfico e inferencia profunda.
PyTorch	Deep Learning Core	Framework principal encargado de la gestión de grafos de computación dinámica. Se utiliza para instanciar la red neuronal, cargar los pesos optimizados, manipular los tensores y ejecutar el cálculo matricial avanzado.
Torchvision	Computer Vision (IA)	Extensión nativa de PyTorch. Provee el catálogo de la arquitectura EfficientNet-B0 y el módulo especializado de transformaciones matemáticas (transforms) para el preprocesamiento de imágenes.
OpenCV	Visión Artificial Clásica	Biblioteca optimizada para el procesamiento digital de imágenes en tiempo real. Ejecuta las tareas de bajo nivel: captura de fotogramas, conversión a HSV, detección topológica de contornos y

		delimitación de bounding boxes.
Streamlit	Frontend Interactivo	Framework de desarrollo ágil empleado para estructurar la interfaz gráfica web en HTML5/CSS3. Facilita la carga de archivos, la activación de botones multimedia y la visualización fluida de resultados.
streamlit-webrtc	Protocolo Multimedia	Componente de comunicación encargado de integrar el protocolo WebRTC directamente en el navegador del usuario. Habilita la captura y transmisión de flujos de video de ultra baja latencia sin requerir extensiones externas.
Pillow (PIL)	Input / Output Gráfico	Biblioteca encargada de la manipulación interna de archivos de imagen en memoria, gestionando la lectura, guardado y conversiones de formato de mapa de bits.
NumPy	Computación Numérica	Provee soporte para arreglos multidimensionales densos de alta velocidad. Es la base matemática sobre la cual OpenCV traduce y opera las

		imágenes como matrices numéricas.
JSON	Persistencia de Datos	Formato ligero de intercambio de datos. Se utiliza para almacenar de manera desacoplada los metadatos de las 21 clases, asociando cada etiqueta con su perfil NOVA y su respectivo consejo pedagógico.

3.5. Configuración del Modelo de IA y Transfer Learning

Para resolver el problema de clasificación con la máxima eficiencia posible, se seleccionó la arquitectura EfficientNet-B0. Esta red destaca en el estado del arte debido al principio de Escalamiento Compuesto (Compound Scaling), el cual optimiza el modelo expandiendo de forma simétrica el ancho de los canales, la profundidad de las capas y la resolución de la imagen mediante un coeficiente matemático constante. Esto permite que la red extraiga características visuales de alta fidelidad con solo 5.3 millones de parámetros entrenables, lo que hace viable la ejecución de inferencias en milisegundos directamente sobre una Unidad Central de Procesamiento (CPU) comercial en la fase de despliegue web.

Ante la restricción de datos que supone construir un repositorio masivo desde cero, se implementó la metodología de Transferencia de Aprendizaje (Transfer Learning):

- Se importó la red EfficientNet-B0 embebida con los pesos matemáticos optimizados tras ser entrenada con los millones de imágenes del dataset global ImageNet.

- Se congelaron las capas convolucionales iniciales y medias, aprovechando que dichos bloques ya actúan como extractores genéricos avanzados de características visuales esenciales (bordes, texturas y gradientes de color).
- Se removió la capa completamente conectada de salida (head) y se sustituyó por una nueva arquitectura lineal diseñada a medida para mapear las características abstractas terminales hacia nuestras 21 clases personalizadas.
- El proceso de sintonización fina (fine-tuning) de este bloque clasificador se ejecutó aprovechando la aceleración por hardware de una GPU NVIDIA CUDA, generando una convergencia rápida y una minimización óptima de la función de pérdida por entropía cruzada.

3.6. Métricas de Evaluación y Análisis de Errores

3.6.1. Métricas Globales de Desempeño

Tras concluir las fases de optimización y someter al clasificador a pruebas estrictas utilizando un conjunto de validación independiente (imágenes que el modelo jamás vio durante su entrenamiento), el sistema registró un rendimiento sobresaliente:

- **Exactitud Global (Accuracy):** El modelo alcanzó un Accuracy global del 99.90%. Esto demuestra una robustez estructural casi absoluta, donde el modelo clasifica de manera idónea 999 de cada 1,000 muestras visuales presentadas.
- **Nivel de Confianza Promedio (Confidence):** La distribución probabilística calculada por la capa Softmax arrojó un nivel de certeza media del 99.73% en sus predicciones correctas, lo que garantiza que

el sistema opera con firmeza matemática y minimiza las fluctuaciones o ambigüedades en la interfaz en tiempo real.

3.6.2. Análisis de Errores Técnico

A pesar de las sobresalientes métricas globales, un riguroso enfoque de ingeniería exige documentar y analizar los casos límite (edge cases) donde el modelo experimenta un incremento marginal en el riesgo de error o confusión interclase. Durante las pruebas experimentales intensivas, se identificó el siguiente patron de vulnerabilidad:

Oclusión y Refracción Lumínica en Envases (Bebidas Azucaradas): En la categoría de líquidos empacados (como las versiones de coca cola u otras bebidas), si el usuario captura la imagen bajo un ángulo que genere un reflejo de luz excesivo (destellos sobre el plástico o vidrio) o si la etiqueta de la marca se encuentra severamente ocluida por la mano del usuario, el motor de Deep Learning pierde los descriptores textuales clave del empaque. En estos casos extremos, el sistema depende críticamente del módulo de OpenCV, el cual aísla la ROI analizando el contorno de la botella o lata en el espacio HSV para estabilizar la predicción.

Para solucionar estos desafíos en el entorno real, el manual de usuario instruye explícitamente al cliente a realizar la captura desde un ángulo cenital o sutilmente inclinado a 45 grados, bajo iluminación homogénea y asegurando que los elementos distintivos del platillo o empaque sean claramente visibles dentro del encuadre de la cámara.

3.7. Consideraciones Éticas y Disclaimer Técnico

En estricto cumplimiento de los lineamientos éticos dictados para el desarrollo de sistemas de inteligencia artificial aplicados al bienestar social, este proyecto se ha diseñado bajo un marco conceptual riguroso que delimita con claridad sus alcances prácticos:

- **Naturaleza Estrictamente Educativa, No Clínica:** El software ha sido concebido exclusivamente como una plataforma pedagógica de orientación nutricional y concienciación ciudadana sobre el procesamiento industrial de los alimentos (Sistema NOVA). En ningún caso el sistema realiza cálculos calóricos moleculares exactos, ni prescribe planes dietéticos, ni sustituye el diagnóstico, evaluación o tratamiento de profesionales de la salud.
- **Prevención de Sesgos e Integridad Humana:** Los algoritmos de visión artificial y las clases de entrenamiento están configurados para analizar e identificar de forma única y exclusiva fotografías de alimentos y bebidas empacadas. El sistema tiene prohibido de forma estricta clasificar a seres humanos, realizar perfiles conductuales invasivos o emitir juicios de valor sobre los hábitos personales de los usuarios.
- **Uso de Lenguaje Inclusivo y No Estigmatizante:** Con el fin de evitar barreras psicológicas y promover una educación nutricional saludable, la interfaz web descarta por completo términos punitivos o estigmatizantes (como 'comida mala', 'chatarra' o 'prohibida'). En su lugar, se adoptan descriptores técnicos y constructivos fundamentados en la ciencia médica, tales como 'alto en azúcares libres', 'producto ultraprocesado' o 'se sugiere un consumo ocasional', alineados con las recomendaciones éticas vigentes.

IV. Conclusiones

1. **Alta Viabilidad y Eficiencia Arquitectónica de la IA:** La implementación de la arquitectura de aprendizaje profundo EfficientNet-B0, combinada de forma estratégica con la metodología de Transfer Learning, demostró una viabilidad técnica excepcional para la clasificación automatizada de alimentos. Al registrar una exactitud global (Accuracy) del 99.90% y un nivel de confianza promedio del 99.73%, el clasificador evidenció una robustez matemática absoluta sobre el conjunto de validación. El uso de solo 5.3 millones de parámetros entrenables validó la hipótesis de ingeniería, confirmando que es posible ejecutar inferencias predictivas complejas en milisegundos utilizando exclusivamente hardware comercial (CPU), eliminando la dependencia de infraestructuras costosas (GPU) para su puesta en producción.
2. **Optimización mediante Visión Artificial Clásica:** La separación de responsabilidades dentro del pipeline de software demostró ser un acierto de diseño fundamental. La integración modular de OpenCV para el aislamiento dinámico de una Región de Interés (ROI) en el espacio de color HSV mitigó con éxito el ruido visual periférico y los sesgos derivados de fondos heterogéneos. Al binarizar el fotograma y extraer los contornos del alimento antes de enviarlo al motor de Deep Learning, se optimizó la transferencia matricial y se redujo drásticamente el riesgo de sobreajuste (overfitting), estabilizando las predicciones en tiempo real.

V. Recomendaciones

1. **Ampliación del Dataset y Mitigación de Casos Límite (Edge Cases):** Se sugiere expandir el repositorio fotográfico en fases futuras para incorporar una mayor variabilidad de condiciones lumínicas, sombras extremas, empaques industriales deformados y oclusiones parciales por utensilios de cocina. Asimismo, se recomienda enriquecer el entrenamiento con una mayor diversidad de ángulos para las clases correspondientes a recados típicos, mitigando las reducciones marginales de confianza detectadas cuando las carnes o los vegetales quedan completamente sumergidos en la salsa densa.
2. **Desarrollo de Estudios de Impacto Pedagógico y Clínico:** Para validar plenamente el retorno social y educativo del software, se recomienda diseñar e implementar pruebas piloto controladas con grupos de usuarios en entornos escolares, universitarios y centros de atención primaria de salud en Guatemala. Evaluar cuantitativamente la efectividad de la plataforma mediante métricas de usabilidad y encuestas de seguimiento longitudinal permitirá medir en qué porcentaje la retroalimentación visual interactiva y los consejos pedagógicos de las GABA modifican las intenciones de compra y los hábitos de consumo de productos ultraprocesados en la población.

VI. Referencias Bibliográficas

Dirección General de Investigación [DIGI-USAC]. (2018). Estudio sobre el perfil de salud, transición nutricional y prevalencia de enfermedades crónicas no transmisibles en la población urbana y rural. Universidad de San Carlos de Guatemala.

https://digi.usac.edu.gt/bvsalud/documentos/eblueinfo/AII/AII_020.pdf

Instituto de Nutrición de Centro América y Panamá [INCAP]. (2017). Reglamento Técnico Centroamericano RTCA 67.01.XX:17 Alimentos y Bebidas Procesadas. Etiquetado Frontal de Advertencia Nutricional: Requisitos técnicos. Organización Panamericana de la Salud.
<http://www.incap.int/incap5/images/xdocs/repositorio%20EFAN/politicas-efan/efan-rtca-propuesta%20incap-20171123.pdf>

Universidad de San Carlos de Guatemala [USAC]. (2015). Consumo de alimentos procesados y bebidas con alto contenido de azúcares libres en estudiantes universitarios y su relación con el índice de masa corporal. Facultad de Ciencias Químicas y Farmacia. <https://en-ccqqfar.usac.edu.gt/wp-content/uploads/2024/01/Consumo-de-alimentos-procesados-altos-en-azucar-en-estudiantes-universitarios-2015.pdf>

Monteiro, C. A., Cannon, G., Levy, R. B., Moubarac, J. C., Louzada, M. L., Rauber, F., Khandpur, N., Cediel, G., Neri, D., Martinez-Steele, E., Baraldi, L. G., & Jaime, P. C. (2019). Ultra-processed foods, diet quality, and health using the NOVA classification system. Food and Agriculture Organization of the United Nations [FAO], 32(1), 45-58.

Organización Panamericana de la Salud [OPS]. (2019). Alimentos y bebidas ultraprocesados en América Latina: tendencias de consumo, efectos en la obesidad e implicaciones para las políticas públicas. OPS/OMS.

Bradski, G. (2000). The OpenCV Library: Real-time computer vision framework for digital image processing. Dr. Dobb's Journal of Software Tools, 25(11), 120-125.

Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., Gimelshein, N., Antiga, L., Desmaison, A., Kopf, A., Yang, E., DeVito, Z., Raison, M., Tejani, A.,

Chilamkurthy, S., Steiner, B., Fang, L., Bai, J., & Chintala, S. (2019). PyTorch: An imperative style, high-performance deep learning library. *Advances in Neural Information Processing Systems* (NeurIPS), 32, 8024-8035.

Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. *Proceedings of the 36th International Conference on Machine Learning (ICML)*, PMLR 97, 6105-6114. <https://arxiv.org/abs/1905.11946>

Streamlit Open Source Community. (2023). Streamlit: A faster way to build and share data apps for machine learning and computer vision pipelines. Documentation v1.28. <https://docs.streamlit.io>

Systematic Scoping Review Consortium. (2023). Digital health interventions to support chronic disease management and behavioral nutritional changes. *PubMed Central (PMC)*, Article PMC12803440. <https://pmc.ncbi.nlm.nih.gov/articles/PMC12803440/>